Text Categorization

Student: Melemciuc Marius-Constantin

Problema

- Clasificarea documentelor pe topic-uri/domenii
- Dataset Reuters-21578
 - o 21578 Docs
 - 20856 Train Docs
 - 722 Test Docs
- Luăm cele mai populare 10 topic-uri T
 - Pentru fiecare topic T_i , 0 < i < 10
 - Train
 - Documentul de train D_{k1} este de tipul T sau non-T
 Avem construit modelul
 - Test
 - Clasificăm documentul de test D_{1/2} ca T sau non-T, pe baza **modelului**
 - Pe baza Test obţinem
 - *Precision* abilitatea de a nu clasifica pozitiv un doc ce este negativ
 - *Recall* abilitatea de a clasifica corect **toate** pozitivele
 - F1 media armonică Precision și Recall

Exemplu Test

- Document Labels
 - o grain
 - o non-grain

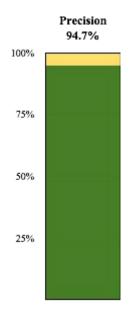
- Train Docs
 - 583 grain
 - 20273 **non-grain**

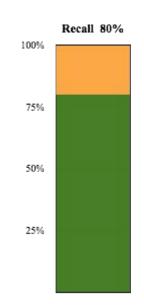
- Test Docs
 - o 45 grain
 - o 677 non-grain

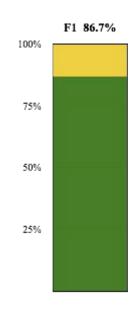
Confusion Matrix



36	2
9	675

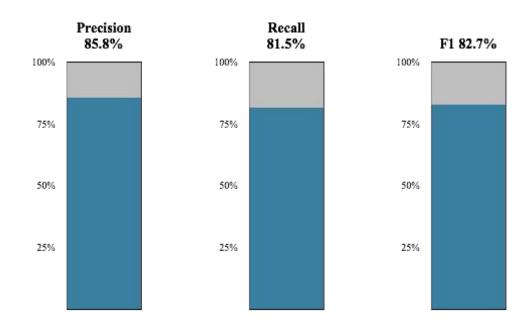






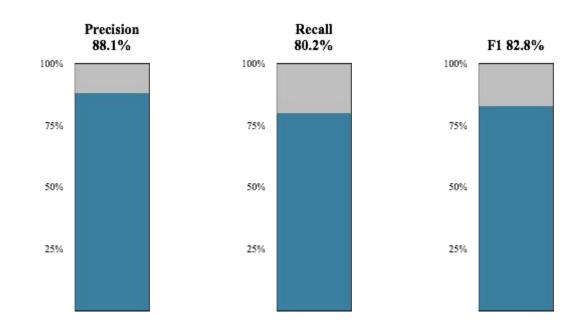
Media testelor

- Aplicând
 - Remove stopwords
 - o Stemming



• Aplicând

Remove stopwords



• Fără

- Remove stopwords
- o Stemming

